
Влияние моделей источников (быстрых БЯМ) на качество декодирования текста при помощи ЭЭГ-спеллера

Барабанщиков М. А.
автор

Майсурадзе А. И.
научный руководитель и консультант

Аннотация

Исследуется влияние моделей источника на декодирование текста в ЭЭГ-спеллере на основе вызванного потенциала Р300. Языковая модель задаёт априорное распределение следующего символа по уже введённому тексту, а ЭЭГ-классификатор оценивает свидетельства о выборе при предъявлении стимулов. Рассматриваются статистическая модель и локальная быстрая большая языковая модель, а также две стратегии предъявления: статическая с фиксированным набором символов и динамическая, изменяющая набор кандидатов с сохранением доступа ко всем символам. Задача формулируется как минимизация ошибки декодирования и времени ввода при ограничении на задержку системы. Предлагается сравнить конфигурации при общем классификаторе ЭЭГ и единых разбиениях данных; качество предполагается оценивать как в офлайн-режиме, так и при онлайн-вводе текста.

Ключевые слова: ЭЭГ-спеллер, интерфейс мозг-компьютер, Р300, языковая модель, декодирование текста.

1 Введение

Интерфейсы мозг-компьютер позволяют вводить текст без обычного движения рук или речи, что особенно важно для людей с тяжёлыми двигательными нарушениями. В ЭЭГ-спеллере пользователь выбирает символ, сосредоточивая внимание на зрительном стимуле; вызванный потенциал Р300 в электроэнцефалограмме помогает определить намерение. Однако для каждой буквы приходится предъявлять стимулы и накапливать достаточно свидетельств, поэтому ошибки распознавания и длительное время выбора ограничивают практическую скорость общения. Цель этой работы — выяснить, насколько контекстно-зависимая модель источника может улучшить декодирование текста при приемлемой вычислительной задержке.

Модель источника задаёт априорную вероятность следующего символа по уже набранному тексту; классификатор ЭЭГ оценивает свидетельство о выборе на основе сигнала. Их сочетание позволяет ранжировать кандидатов с учётом обеих частей информации. В PolyMorph контекст использовался для изменения матрицы выбора и предсказания слов [1]; позднее GPT-2 применяли для оптимизации стимулов и подсказок в Р300-спеллере [2]. ChatBCI показал онлайн-ввод с подсказками большой языковой модели через удалённый сервис [3], а MindChat исследовал похожие подсказки для SSVEP-спеллера [4].

Эти результаты подтверждают пользу языкового контекста, но сопоставлять их количественно трудно: различаются парадигмы стимуляции, состав интерфейса, способ оценки и доступность модели. В частности, выигрыш от подсказок слов не равен выигрышу от более точного априорного распределения по символам, а моделирование ЭЭГ не заменяет онлайн-испытание. Отдельная линия работ переводит ЭЭГ при чтении текста непосредственно в слова: DeWave [5], метод Wang и Ji [6] и модель с контрастивным предобучением [7] решают

иную задачу, поэтому их метрики не служат прямой базой для P300-спеллера. Критический анализ [8] дополнительно показывает необходимость оценки без утечки правильного текста и с контролем вклада нейросигнала.

Предлагается единая конфигурируемая система, в которой один и тот же декодер ЭЭГ можно сочетать со статистической моделью или быстрой БЯМ. Рассматриваются две стратегии: статическая сохраняет фиксированный набор предъявляемых символов и меняет только априорные вероятности; динамическая также адаптирует набор кандидатов на экране. Основной исследовательский вопрос состоит в том, даёт ли динамическая стратегия устойчивый выигрыш по сравнению со статической при сопоставимых условиях, одном классификаторе и одинаковом ограничении на задержку. Система позволяет отделить вклад языковой модели от вклада интерфейса и проверить обе стратегии в одном протоколе; возможная цена динамической стратегии — дополнительное время вычисления и изменение стимуляции.

Для проверки предусмотрены офлайн-сравнение на одинаковых разбиениях ЭЭГ и онлайн-ввод текста участниками. Базовыми конфигурациями служат декодирование без языковой модели, со статистической моделью и с быстрой БЯМ; статическое и динамическое предъявление сравниваются при одинаковом классификаторе ЭЭГ. Критерии оценки включают точность классификации P300 и выбора символа, скорость ввода, частоту исправления ошибок, качество предсказаний и полную задержку отклика. Эффект динамической стратегии необходимо проверять онлайн, поскольку изменение стимулов меняет собираемый ЭЭГ-сигнал и не всегда воспроизводится по записям, полученным при фиксированной раскладке.

Предлагаемый вклад.

- Единый протокол сравнения статистических и быстрых нейросетевых моделей источника в P300-спеллере.
- Сопоставление статического и динамического предъявления символов при общем декодере ЭЭГ.
- Протокол офлайн- и онлайн-оценки точности, скорости и задержки с разделением обучающих и контрольных данных.

Структура статьи. Далее рассмотрены связанные работы и приведена формальная постановка задачи.

2 Обзор литературы

Контекст и адаптация в P300-спеллерах. Ранний PolyMorph [1] удаляет малополезные символы из матрицы и предсказывает слова по контексту предложения. Это показывает, что языковая информация может менять не только решение декодера, но и сами стимулы. Parthasarathy и соавторы [2] совместили GPT-2 с оптимизацией предъявления и предсказанием слов; сообщаемый выигрыш получен преимущественно в моделировании на выборках ЭЭГ. Оба подхода важны как базовые, но не дают прямого сравнения современных быстрых БЯМ и статистических априорных моделей при одном онлайн-протоколе.

Подсказки большой языковой модели. В ChatBCI [3] слова и продолжения фразы становятся дополнительными клавишами P300-интерфейса. Онлайн-эксперимент с семью участниками подтверждает, что подсказки сокращают число выборов, однако обращения к удалённому GPT-3.5 не отвечают на вопрос о задержке локальной быстрой модели. MindChat [4] расширяет идею контекстных подсказок до слов и предложений, но использует SSVEP, поэтому его показатели скорости нельзя напрямую сопоставить с P300. Для настоящей работы нужны две независимые переменные: качество распределения вероятностей символов и способ предъявления кандидатов.

Декодирование текста непосредственно из ЭЭГ. Wang и Ji [6], DeWave [5] и Wang с соавторами [7] соединяют нейросигнал и языковые представления в задаче перевода ЭЭГ, записанной при чтении, в текст. Последние две работы опубликованы на NeurIPS и ACL соответственно и показывают развитие методов сопряжения ЭЭГ с языковыми моделями. Однако они не используют выбор символов по P300, а их BLEU и ROUGE описывают восстановление текста, а не скорость ввода. Более того, для ранней модели Wang и Ji была обнаружена ошибка

оценки; анализ Jo и соавторов [8] требует тестировать модель без подстановки правильного продолжения и сравнивать её с контролем на шумовом сигнале.

Вывод. Ближайшие базовые подходы — P300 без языковой модели, P300 со статистическим априорным распределением и P300 с предсказанием текста посредством БЯМ. Пробел состоит в сопоставлении этих подходов на общих данных и в проверке, окупает ли динамическое изменение набора стимулов дополнительные вычисления. Именно эту проверку должен обеспечить предлагаемый эксперимент.

3 Постановка задачи

Требуется выбрать намеренный пользователем символ по последовательности предъявленных стимулов, фрагментам ЭЭГ и ранее введённому тексту. Исследовательский вопрос состоит в том, как выбор модели источника и способа предъявления символов влияют на ошибку декодирования и время ввода при одинаковом классификаторе ЭЭГ и заданном ограничении на задержку.

Данные и обозначения. Пусть $\mathcal{A}$ — конечный алфавит доступных символов. Выборка $\mathcal{D}_\pi = \{(h_i, y_i, X_i)\}_{i=1}^{n_\pi}$, собранная при политике предъявления π , состоит из контекста $h_i \in \mathcal{A}^*$ перед очередным выбором, намеренного символа $y_i \in \mathcal{A}$ и записи $X_i = \{(x_{ij}, S_{ij})\}_{j=1}^{m_i}$. Здесь x_{ij} — фрагмент ЭЭГ после j -го предъявления, а S_{ij} — предъявленная группа клавиш. Целевая метка предъявления равна $z_{ij} = \mathbf{1}\{g_{C_i}(y_i) \in S_{ij}\}$. Отображение g_{C_i} оставляет символы текущего набора $C_i \subseteq \mathcal{A}$ без изменения и переводит остальные в клавишу «Другие». При её выборе открывается полный алфавит; поэтому каждый y_i остаётся доступным и при динамической раскладке.

Класс моделей и правило решения. Модель источника $p_\phi(c \mid h)$ задаёт положительную априорную вероятность $c \in \mathcal{A}$; рассматриваются равномерное распределение без языковой модели, статистическая модель и быстрая БЯМ. Классификатор ЭЭГ с параметрами θ оценивает калиброванное логарифмическое отношение правдоподобий $s_\theta(x) = \log[p_\theta(x \mid z = 1)/p_\theta(x \mid z = 0)]$. Политика π задаёт набор клавиш и группы стимулов: статическая использует $C_i = \mathcal{A}$, динамическая выбирает $C_i = \pi(h_i)$ и применяет описанный возврат к полному алфавиту. Для $a \in C_i \cup \{\text{Другие}\}$ априорная масса $p_\phi^{(C_i)}(a \mid h_i)$ равна $p_\phi(a \mid h_i)$ для символа и сумме вероятностей исключённых символов для клавиши «Другие». После предъявлений оценка выбора имеет вид

$$q_{\theta, \phi, \pi}(a \mid X_i, h_i) = \frac{p_\phi^{(C_i)}(a \mid h_i) \exp\left(\sum_{j=1}^{m_i} \mathbf{1}\{a \in S_{ij}\} s_\theta(x_{ij})\right)}{\sum_{b \in C_i \cup \{\text{Другие}\}} p_\phi^{(C_i)}(b \mid h_i) \exp\left(\sum_{j=1}^{m_i} \mathbf{1}\{b \in S_{ij}\} s_\theta(x_{ij})\right)}. \quad (1)$$

Окончательная вероятность $P_{\theta, \phi, \pi}(y_i \mid X_i, h_i)$ учитывает также второй этап выбора, если была нажата клавиша «Другие»; итоговый символ определяется максимумом этой вероятности. Формула (1) предполагает условную независимость свидетельств предъявлений при заданном намеренном символе; калибровка s_θ и устойчивость к нарушению этого предположения подлежат проверке.

Критерий и ограничения. Пусть $T_i(\theta, \phi, \pi)$ — полное время выбора символа, включая повторные предъявления, переход через клавишу «Другие» и вычисление модели. При $\lambda \geq 0$ внутренний критерий объединяет логарифмическую ошибку и время ввода:

$$Q_{\mathcal{D}_\pi}(\theta, \phi, \pi) = \frac{1}{n_\pi} \sum_{i=1}^{n_\pi} [-\log P_{\theta, \phi, \pi}(y_i \mid X_i, h_i) + \lambda T_i(\theta, \phi, \pi)], \quad (2)$$

$$(\theta^*, \phi^*, \pi^*) \in \arg \min_{(\theta, \phi, \pi) \in \mathcal{H}, L_{\text{sys}} \leq L_{\text{max}}} Q_{\mathcal{D}_\pi}(\theta, \phi, \pi).$$

Здесь $\mathcal{H}$ — допустимые конфигурации классификатора, модели источника и политики, L_{sys} — задержка отклика системы, а L_{max} — её допустимая граница. Значение λ и граница задержки фиксируются до сравнения конфигураций. Внешние критерии — точность P300 и конечного символа, символы в минуту, частота исправлений и задержка отклика; они сообщаются отдельно, поскольку одно значение $Q_{\mathcal{D}_\pi}$ не описывает все практические свойства spellера.

Для оценки без утечки контексты, фразы и ЭЭГ одного участника не должны попадать одновременно в обучающую и контрольную части соответствующего протокола. Обучение и подбор параметров проводятся без доступа к контрольным меткам. Офлайн-записи позволяют сопоставлять модели источника при совместимых стимулах; влияние динамического предъявления на сигнал и реальную скорость требует онлайн-проверки.

Список литературы

- [1] Alberto Casagrande, Joanna Jarmolowska, Marcello Turconi, Francesco Fabris, Pierpaolo Busan, and Piero Paolo Battaglini. PolyMorph: Increasing P300 spelling efficiency by selection matrix polymorphism and sentence-based predictions, 2015. URL <https://arxiv.org/abs/1502.04485>.
- [2] Nithin Parthasarathy, James Soetedjo, Saarang Panchavati, Nitya Parthasarathy, Corey Arnold, Nader Pouratian, and William Speier. High performance P300 spellers using GPT2 word prediction with cross-subject training. *Brain-Computer Interfaces*, 11(4):210–224, 2024. doi: 10.1080/2326263X.2024.2413214. URL <https://arxiv.org/abs/2405.13329>.
- [3] Jiazhen Hong, Weinan Wang, and Laleh Najafizadeh. ChatBCI, a P300 speller BCI with context-driven word prediction leveraging large language models, from concept to evaluation. *Scientific Reports*, 16:6379, 2026. doi: 10.1038/s41598-025-25660-7. URL <https://arxiv.org/abs/2411.15395>.
- [4] Jiaheng Wang, Yucun Zhong, Chengjie Huang, and Lin Yao. MindChat: Enhancing BCI spelling with large language models in realistic scenarios, 2025. URL <https://arxiv.org/abs/2507.21435>.
- [5] Yiqun Duan, Jinzhao Zhou, Zhen Wang, Yu-Kai Wang, and Chin-Teng Lin. DeWave: Discrete encoding of EEG waves for EEG to text translation. In *Advances in Neural Information Processing Systems*, volume 36, 2023. URL <https://arxiv.org/abs/2309.14030>.
- [6] Zhenhailong Wang and Heng Ji. Open vocabulary electroencephalography-to-text decoding and zero-shot sentiment classification. In *Proceedings of the AAAI Conference on Artificial Intelligence*, volume 36, pages 5350–5358, 2022. doi: 10.1609/aaai.v36i5.20472. URL <https://arxiv.org/abs/2112.02690>.
- [7] Jiaqi Wang, Zhenxi Song, Zhengyu Ma, Xipeng Qiu, Min Zhang, and Zhiguo Zhang. Enhancing EEG-to-text decoding through transferable representations from pre-trained contrastive EEG-text masked autoencoder. In *Proceedings of the 62nd Annual Meeting of the Association for Computational Linguistics*, pages 7278–7292, 2024. doi: 10.18653/v1/2024.acl-long.393. URL <https://arxiv.org/abs/2402.17433>.
- [8] Hyejeong Jo, Yiqian Yang, Juhyeok Han, Yiqun Duan, Hui Xiong, and Won Hee Lee. Are EEG-to-text models working?, 2024. URL <https://arxiv.org/abs/2405.06459>.