Влияние моделей источника на качество декодирования текста в ЭЭГ-спеллере

Барабанщиков М. А.
Автор

Майсурадзе А. И.
Научный руководитель и консультант

Аннотация

Исследуется влияние языковой модели на выбор букв в ЭЭГ-спеллере — системе ввода текста по реакциям на зрительные стимулы. Вероятности букв по предшествующему тексту объединяются с оценкой реакции. В системе BioSpeller сравниваются режим без языковой информации, символьная 4-граммная модель и словная модель KenLM. Для 40 русскоязычных фраз выполнено по пять полных прогонов с разным случайным шумом в синтетических оценках реакции. При правильном контексте KenLM повышает точность выбора символа с 80,63% до 93,47%. При последовательном вводе доля символьных ошибок (CER) составляет 19,10% без языка, 12,67% для 4-граммы и 11,89% для KenLM. Снижение CER для KenLM относительно режима без языка равно 37,75%. Последующая коррекция текста отключена; параметры сигнала и правило выбора одинаковы для всех моделей.

1 Введение

Спеллер — система посимвольного ввода текста с экранной клавиатуры. В ЭЭГ-спеллере пользователь удерживает внимание на нужной букве, а программа подсвечивает строки и столбцы. Реакции, зарегистрированные с помощью электроэнцефалографии (ЭЭГ), позволяют определить целевой символ на их пересечении. Такие системы исследуются как средство коммуникации для людей с тяжёлыми двигательными нарушениями [1, 2]. Существуют и другие способы предъявления стимулов; здесь рассматривается строково-столбцовая схема.

BioSpeller — программная реализация такого интерфейса. Для выбора буквы используются два источника информации: модуль обработки сигнала оценивает реакцию на подсветку, а языковая модель — вероятности следующих символов по набранному тексту. Например, после «приве» вероятна буква «т». Эти вероятности называют априорным распределением, а языковую модель — моделью источника. Декодер объединяет обе оценки и выбирает символ. Язык помогает при неоднозначной реакции. Расчёт перед каждой буквой должен быть быстрым.

Языковая информация используется в P300-спеллерах, распознающих реакцию на значимый стимул, в том числе в байесовских декодерах и скрытых марковских моделях [3, 4]; обзор методов представлен в [5]. Важно оценивать прогноз и при ошибках в набранном тексте: проверка только на правильном начале фразы не отражает их накопление.

Цель работы — сравнить быстрые языковые модели с режимом без языка. При едином декодере оцениваются прогноз следующего символа, выбор при правильном начале фразы и ввод с собственными ошибками.

2 Модели источника и постановка задачи

Пусть $\mathcal{A}$ — множество элементов клавиатуры. В эксперименте их 36: 32 русские буквы без «ё», пробел, точка, запятая и удаление; сам подход допускает другой алфавит. Один шаг t означает выбор одного элемента. Контекст h_t — уже набранный текст, а наблюдения E_t — числовые оценки реакции на подсветки. Один цикл включает подсветку всех шести строк и шести столбцов. Число таких циклов перед выбором одного символа обозначается R.

Модель M назначает каждому кандидату c вероятность $p_M(c \mid h_t)$ по тексту. Правдоподобие $\ell_t(c) \propto P(E_t \mid c)$ показывает, насколько наблюдаемые реакции согласуются с предположением, что пользователь выбрал именно c. Языковое распределение и оценки сигнала передаются декодеру раздельно.

Таблица 1: Способы построения априорного распределения символов.

Источник	Распределение символов	Используемый контекст
Равномерный	Одинаковая вероятность $1/36$	Предшествующий текст не учитывается.
Char4	Символьная 4-граммная модель	До трёх предыдущих символов.
KenLM	Словная модель в смеси с Char4	Завершённые слова и начало текущего слова.

Char4 оценивает следующую букву по частотам сочетаний до четырёх символов, включая предсказываемый. KenLM — библиотека для работы со словными n-граммными моделями [6]. Здесь используются готовые веса из набора `jonatasgrosman/wav2vec2-large-xlsr-53-russian`. Чтобы получить вероятности букв, суммируются вероятности слов, продолжающих набранное начало слова (префикс) одной и той же следующей буквой. Словарь ограничен 60 000 словами. Итоговое распределение смешивается с Char4 с весами $0{,}9$ и $0{,}1$; при отсутствии подходящих слов используется символьная модель. Вероятность удаления для обоих языковых источников равна $0{,}02$. Дообучение моделей на тестовых фразах не проводится.

2.1 Критерии качества

Сначала оценивается только языковой прогноз, без сигнала. Модели передаётся правильное начало фразы $h_t = x_{<t}$, где x_t — следующий эталонный символ. Top-1 — доля позиций, на которых правильный символ получил наибольшую вероятность. BPC (bits per character) — средняя логарифмическая потеря по N проверенным символам; чем она меньше, тем выше вероятность, назначаемая правильному продолжению:

$$\mathrm{BPC}(M) = -\frac{1}{N}\sum_{t=1}^{N} \log_2 \widetilde{p}_M(x_t \mid x_{<t}), \tag{1}$$

В эталонном тексте нет команды удаления. Поэтому для BPC её исключают, а вероятности 35 печатных символов делят на оставшуюся сумму: $\widetilde{p}_M(c \mid h) = p_M(c \mid h)/(1 - p_M(\text{удаление} \mid h))$. Их сумма снова равна единице. При декодировании сохраняются все 36 вариантов.

Качество итогового текста измеряется CER (character error rate): числом необходимых исправлений, делённым на длину эталона. Для заданной фразы x_i и набранной $\hat{x}_i$:

$$\mathrm{CER}(M) = \frac{\sum_i d_{\mathrm{Lev}}(x_i, \hat{x}_i^{M})}{\sum_i |x_i|}, \qquad M^* \in \operatorname*{arg\,min}_{M \in \{\text{uniform},\text{Char4},\text{KenLM}\}} \mathrm{CER}(M), \tag{2}$$

Здесь d_{Lev} — минимальное число вставок, удалений и замен для получения эталона, а M^* — модель с наименьшей CER среди сравниваемых. Например, одна замена в тексте из 20 символов даёт CER $= 5\%$.

3 Декодирование с языковой информацией

Итоговое распределение $q_t(c)$ учитывает и текст, и реакцию на подсветки. Декодер выбирает его наиболее вероятный элемент $\hat{c}_t$:

$$q_t(c) = \frac{p_M(c \mid h_t)^{\alpha} \ell_t(c)^{\beta}}{\sum_{a \in \mathcal{A}} p_M(a \mid h_t)^{\alpha} \ell_t(a)^{\beta}}, \qquad \hat{c}_t = \arg\max_{c \in \mathcal{A}} q_t(c). \tag{3}$$

Параметры α и β задают веса языковой информации и сигнала; здесь оба равны единице. Выбранный символ добавляется к тексту; команда удаления убирает последний символ. Перед следующим выбором языковое распределение пересчитывается по обновлённому контексту.

Утверждение 1. *Если $p_M(c \mid h)$ соответствует априорной вероятности выбора символа, $\ell(c) \propto P(E \mid c)$ и наблюдения условно независимы от истории при заданном символе, то при $\alpha = \beta = 1$ распределение* (3) *является апостериорным. Выбор его максимума минимизирует условную вероятность ошибки одного решения.*

Доказательство. По формуле Байеса $P(c \mid E, h) \propto P(E \mid c, h) P(c \mid h)$. Условная независимость даёт $P(E \mid c, h) = P(E \mid c)$, после чего нормировка приводит к (3). При функции потерь 0–1 риск выбора a равен $1 - q(a)$ и минимален в точке максимума q. □

Влияние языка выражается через отношение вероятностей: символ a предпочтительнее b, если $\log \ell(a) - \log \ell(b) > \log p_M(b) - \log p_M(a)$. Таким образом, вероятное по языку продолжение может быть выбрано даже при менее убедительной реакции на него. После расчёта априорных вероятностей объединение распределений и поиск максимума требуют $O(|\mathcal{A}|)$ операций.

4 Организация эксперимента

В BioSpeller меняется только модель источника; декодер общий, коррекция готового текста и подсказки слов отключены. Набор содержит 40 русскоязычных фраз общей длиной 1 406 символов: бытовые просьбы и предложения с менее частой лексикой. Каждую фразу вводят пять раз с разными последовательностями случайного шума. Такой полный ввод далее называется прогоном; он включает много подсветок и выборов букв.

Симулятор выдаёт оценку z реакции на каждую подсветку, которую в реальной системе вычислял бы классификатор ЭЭГ. Сама ЭЭГ не генерируется. По заданной нормальной модели шума $z \sim \mathcal{N}(d', 1)$, если группа содержит нужный символ, и $z \sim \mathcal{N}(0, 1)$ иначе. Первое число — среднее, второе — дисперсия, характеризующая разброс. Перекрытие распределений создаёт ошибки. Сдвиг $d' = 1{,}2$ задаёт сложность симуляции и не оценивался по данным человека. Логарифм отношения этих плотностей равен $d' z - d'^2/2$; эта добавка накапливается для символов подсвеченной группы.

Сравниваются $R = 1, 3, 5$ циклов на один выбор, то есть 12, 36 и 60 подсветок. Это отдельный параметр, не число полных прогонов фразы. Шум подготовлен заранее и используется моделями по одному правилу; после удаления повторная попытка получает новые наблюдения. Досрочный выбор до завершения R циклов отключён.

В первом режиме каждой букве предшествует правильный текст, например «приве» перед «т». Во втором модель видит реально набранное начало, в том числе ошибочное, например «привы». Так отдельно оцениваются выбор буквы и накопление ошибок в тексте.

Задержка расчёта измеряется на CPU одного компьютера после загрузки модели. Медиана и 95-й перцентиль — времена, не превышаемые в 50% и 95% вызовов. Загрузка модели и ожидание подсветок в них не входят.

5 Результаты и обсуждение

Таблица 2: Качество языкового прогноза, ошибка последовательного ввода и задержка расчёта распределения (медиана/95-й перцентиль, мс).

Источник	BPC ↓	Top-1, % ↑	CER, % ↓	Медиана/p95
Без языка	5,13	–	19,10	–
Char4	2,82	40,97	12,67	0,02/0,03
KenLM	2,23	52,63	11,89	0,07/56,57

Прогноз и выбор символа. Top-1 — доля случаев, когда языковая модель поставила правильный следующий символ на первое место по вероятности. KenLM имеет меньшую BPC и более высокую Top-1, чем Char4. После объединения с одинаковыми наблюдениями при пяти циклах подсветки на букву ($R = 5$) точность выбора составляет 80,63% для равномерного распределения, 91,93% для Char4 и 93,47% для KenLM. Прирост KenLM относительно базового режима равен 12,84 п. п. При одном цикле ($R = 1$) точность составляет соответственно 26,93%, 59,99% и 68,83% (рис. 1).

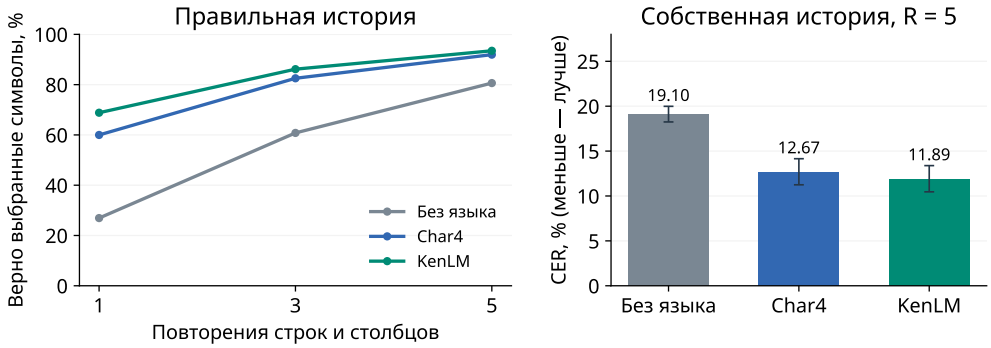


Рисунок 1. Слева: точность после объединения языка с сигналом при правильном начале фразы; по горизонтали — число циклов подсветки R. Справа: ошибка всего текста при вводе с собственными ошибками, $R = 5$. Отрезки — 95%-е доверительные интервалы CER, рассчитанные повторной выборкой фраз.

Последовательный ввод. Для каждой модели выполнено $40 \times 5 = 200$ полных прогонов при пяти циклах подсветки на букву. Всего для трёх моделей завершено 600 прогонов. В каждом режиме оценены $1\,406 \times 5 = 7\,030$ эталонных символов; суммарное расстояние редактирования равно 1 343 без языковой модели, 891 для Char4 и 836 для KenLM. Соответствующие значения CER составляют 19,10%, 12,67% и 11,89%. Относительное снижение ошибки равно 33,66% для Char4 и 37,75% для KenLM.

Вычислительная задержка. Медиана времени расчёта распределения составляет 0,02 мс для Char4 и 0,07 мс для KenLM, а 95-й перцентиль — 0,03 и 56,57 мс. У KenLM время меняется сильнее: количество подходящих слов зависит от уже набранного начала слова. В BioSpeller распределение вычисляется перед началом стимуляции; эти затраты добавляются к паузе между выборами.

6 Заключение

Сравнение трёх моделей источника показало, что языковая информация повышает качество декодирования в исследуемой конфигурации ЭЭГ-спеллера. Символьная и словная модели улучшают выбор отдельных символов при правильном контексте и уменьшают ошибку итогового текста при последовательном вводе. Улучшение достигается на этапе объединения языковых вероятностей с наблюдениями, без последующего исправления фраз.

Наименьшая средняя CER получена для KenLM: 11,89% против 19,10% в базовом режиме, что соответствует относительному снижению на 37,75%. Для Char4 CER равна 12,67%. KenLM также обеспечивает более точный прогноз следующего символа, а преимущество Char4 состоит в меньшей и более равномерной вычислительной задержке. Эти результаты показывают практическую значимость совместной оценки качества декодирования и времени расчёта модели источника.

Раздельная оценка с правильным началом фразы и с фактически набранным текстом позволяет учитывать накопление ошибок ввода. BPC и Top-1 характеризуют качество языкового прогноза, тогда как CER отражает результат взаимодействия источника, сигнала и правила выбора. Поэтому сравнение моделей по итоговому тексту дополняет оценку их предсказательной способности.

Эксперимент проведён на русскоязычных фразах с синтетическими наблюдениями, фиксированными параметрами сигнала и одинаковым числом предъявлений стимулов. Полученные оценки описывают влияние источника в этих условиях. Для воспроизведения сравнения сохранены тестовые фразы, параметры моделей, сгенерированные оценки реакций и последовательности выбранных символов. Измеренная задержка относится к вычислению языкового распределения; скорость коммуникации пользователя в данном эксперименте не оценивалась.

Список литературы

[1] Aya Rezeika, Mihaly Benda, Piotr Stawicki, Felix Gembler, Abdul Saboor, and Ivan Volosyak. Brain-Computer Interface Spellers: A Review. *Brain sciences*, 8(4):E57, 2018. doi: 10.3390/brainsci8040057. URL https://doi.org/10.3390/brainsci8040057.

[2] William Speier, Nand Chandravadia, Dustin Roberts, S Pendekanti, and Nader Pouratian. Online BCI Typing using Language Model Classifiers by ALS Patients in their Homes. *Brain computer interfaces (Abingdon, England)*, 4(1-2):114–121, 2017. doi: 10.1080/2326263x.2016.1252143. URL https://doi.org/10.1080/2326263x.2016.1252143.

[3] William Speier, Corey Arnold, Jessica Lu, Ricky K Taira, and Nader Pouratian. Natural language processing with dynamic classification improves P300 speller accuracy and bit rate. *Journal of neural engineering*, 9(1):016004, 2012. doi: 10.1088/1741-2560/9/1/016004. URL https://doi.org/10.1088/1741-2560/9/1/016004.

[4] William Speier, Corey Arnold, Jessica Lu, Aniket Deshpande, and Nader Pouratian. Integrating language information with a hidden Markov model to improve communication rate in the P300 speller. *IEEE transactions on neural systems and rehabilitation engineering : a publication of the IEEE Engineering in Medicine and Biology Society*, 22(3):678–684, 2014. doi: 10.1109/tnsre.2014.2300091. URL https://doi.org/10.1109/tnsre.2014.2300091.

[5] W Speier, C Arnold, and N Pouratian. Integrating language models into classifiers for BCI communication: a review. *Journal of neural engineering*, 13(3):031002, 2016. doi: 10.1088/1741-2560/13/3/031002. URL https://doi.org/10.1088/1741-2560/13/3/031002.

[6] Kenneth Heafield. Kenlm: Faster and smaller language model queries. In *Proceedings of the Sixth Workshop on Statistical Machine Translation*, pages 187–197, 2011. URL https://aclanthology.org/W11-2123/.